



# Uczenie Maszynowe

Teoria

Joe Mama      Mike Hawk      Nick Ger      Hugh Jass      Bic Didz      Mike Oxlong  
Geega Neega      Sleepy “Slippy” Joe (ocień w końcu kolosy)      TrumpGPT

June 29, 2023

## Abstract

Przygotujcie się na niezapomnianą przygodę z kursem z uczenia maszynowego. Kurs ten zabierze Was w podróż po klasycznych algorytmach uczenia maszynowego, które potrafią zrobić niesamowite rzeczy, takie jak regresja, klasyfikacja, klastrowanie, redukcja wymiarów i wyszukiwanie wzorców. Poznacie również tajemnice sieci neuronowych i ich różnorodne typy. Kurs ten uświadomi Wam również podstawowe problemy, które mogą Wam się nawarzyć podczas uczenia maszynowego i oświeci ich matematyczne źródła. Będziecie w stanie wybrać odpowiedni algorytm uczenia maszynowego w zależności od konkretnego zadania i dostępnych danych. Ponadto, kurs ten obejmuje tematy związane z walidacją modelu i rozwiązywaniem typowych kłopotów, które mogą Wam się przyplątać podczas trenowania modelu. Zdobędziecie umiejętność przeprowadzania walidacji modelu oraz rozwiązywania występujących bolączek.

## Contents

<b>1</b>	<b>Rodzaje uczenia maszynowego</b>	<b>4</b>
<b>2</b>	<b>Metryki</b>	<b>5</b>
2.1	<i>Klasyfikacja</i>	6
2.1.1	Accuracy	6
2.1.2	Precision	6
2.1.3	Recall (True Positive Rate, Sensitivity, Probability of Detection)	7
2.1.4	F1-score	7
2.1.5	Kompromis Precision/Recall	7
2.2	<i>Regresja</i>	7
<b>3</b>	<b>Regresja</b>	<b>8</b>
3.1	Regresja	9
3.1.1	Regresja Liniowa	9
3.1.2	Regresja wielomianowa	9
3.1.3	Regresja Logistyczna	9
3.2	Gradient Descent	9
3.2.1	SGD Stochastic Gradient Descent:	9
3.3	Learning Curves	10
3.3.1	Bias	10
3.3.2	Variance	10
3.3.3	Irreducible Error	10
3.3.4	Kompromis między <i>Bias</i> a <i>Variance</i>	10
3.4	Regularyzowane modele liniowe	10
3.4.1	Ridge Regression	10
3.4.2	Lasso Regression	10
3.4.3	Early Stopping	10
<b>4</b>	<b>SVM (Support Vector Machines)</b>	<b>10</b>
4.1	Hard Margin Classification	11
4.2	Soft Margin Classification	11
4.3	Nieliniowa klasyfikacja SVM	11
4.3.1	Polynomial Kernel	11
4.4	Regresor SVM	11
4.5	Drzewa Decyzyjne	12
4.5.1	White Box vs Black Box	12
4.5.2	Hiperparametry	12
4.5.3	Regresja	13
<b>5</b>	<b>Ensemble Learning i Random Forests</b>	<b>13</b>
5.1	W problemie klasyfikacji rozróżniamy 2 rodzaje klasyfikatorów:	14

5.1.1	<i>Hard Voting Classifier</i>	14
5.1.2	<i>Soft Voting Classifier</i>	14
5.2	Bagging i Pasting	14
5.3	Random Forests	14
5.3.1	Extremely Randomized Trees Ensembly	14
5.4	Boosting	15
5.4.1	AdaBoost	15
5.4.2	Gradient Boosting	15
5.5	Stacking	15
<b>6</b>	<b>Redukcja Wymiarów</b>	<b>15</b>
6.1	Curse of Dimensionality	16
6.2	PCA - Principal Component Analysis	16
6.2.1	SVD - Singular Value Decomposition	17
6.3	Incremental PCA	17
6.4	Rozmaitości	17
6.4.1	LLE - Locally Linear Embedding	17
<b>7</b>	<b>Uczenie nienadzorowane</b>	<b>17</b>
7.1	Soft Clustering	19
7.2	Hard Clustering	19
7.3	DBSCAN	19
7.4	KNN - K-nearest neighbors	20
7.5	Algorytm centroidów (k-średnich) <i>K-Means</i>	20
7.5.1	Wyznaczanie liczby klastrów	22
<b>8</b>	<b>Sieci neuronowe - wprowadzenie</b>	<b>22</b>
8.1	Perceptron	23
8.1.1	Uczenie perceptronu	23
8.2	Funkcje aktywacji	24
8.2.1	Dlaczego potrzebujemy funkcji aktywacji?	24
8.3	Warstwy	26
8.3.1	Warstwa gęsta	26
<b>9</b>	<b>Głębokie sieci neuronowe</b>	<b>26</b>
9.1	Budowa modelu	27
9.1.1	Keras Sequential API	27
9.1.2	Keras Functional API	27
9.2	Kompilacja i uczenie modelu	28
9.3	Callbacks	29
9.4	Analiza procesu uczenia	30
9.5	Przeszukiwanie przestrzeni hiperparametrów	31

9.5.1	SciKit-Learn . . . . .	31
9.5.2	Keras Tuner . . . . .	31
<b>10</b>	<b>Konwolucyjne sieci neuronowe</b>	<b>31</b>
10.1	Konwolucja . . . . .	32
10.2	Typowe błędy podczas projektowania CNN . . . . .	32
10.3	Pooling . . . . .	33
10.4	Dropout . . . . .	33
10.5	Uczenie rezydualne (Residual Learning) . . . . .	33
10.6	Klasyfikacja i Lokalizacja obiektów . . . . .	34
10.6.1	Bounding Boxes . . . . .	34
10.6.2	Fully Convolutional Networks . . . . .	34
10.6.3	YOLO You Only Look Once . . . . .	34
10.6.4	<i>Transponowana warstwa konwolucyjna (Transposed Convolutional Layer)</i> . . . . .	35
10.6.5	Segmentacja semantyczna . . . . .	35
10.6.6	Metryki: . . . . .	35
<b>11</b>	<b>Rekurencyjne sieci neuronowe</b>	<b>35</b>
11.1	Rodzaje RNN ze względu na rodzaj danych wejściowych/wyjściowych . . . . .	36
11.1.1	Sequence to sequence network . . . . .	36
11.1.2	Vector to sequence network ( <b>Dekoder</b> ) . . . . .	36
11.1.3	Sequence to vector network ( <b>Enkoder</b> ) . . . . .	36
11.2	Działanie RNN w kilku krokach: . . . . .	37
11.3	Przewidywanie kilku kroków czasowych do przodu . . . . .	37
11.4	Unrolling (rozwijanie) . . . . .	37
11.5	Osadzenia . . . . .	37
11.6	Rozwiązanie problemu niestabilnych gradientów . . . . .	37
<b>12</b>	<b>Porównania</b>	<b>37</b>
12.1	Modele . . . . .	38

## 1 Rodzaje uczenia maszynowego

Podziały ze względu na:

- nadzór:
  - **uczenie nadzorowane** - trzeba etykietować zbiór uczący
  - **uczenie nienadzorowane** - nie trzeba etykietować zbioru uczącego (uczenie bez nauczyciela)
  - **częściowo nadzorowane** - część danych jest etykietowana, część nie
  - **uczenie przez wzmacnianie** - polega na dawaniu kar i nagród za konkretne wybory, które algorytm uwzględnia przy kolejnych próbach
- sposób uogólnienia:
  - **instancje (nieparametryczny) (np. KNN, drzewa)** - uczenie na pamięć, szuka najbardziej podobnego do pytanego obiektu i podpisuje go tak samo według poznanych zasad, przykład: K-nearest neighbors; przede wszystkim wielkość modelu jest nieznana przed rozpoczęciem uczenia
  - **model (parametryczny) (np. sieci neuronowe, regresja logistyczna, SVM)** - szuka zależności między wartościami i na ich podstawie dobiera parametry funkcji, na podstawie której potem przewiduje wartość; wielkość modelu jest znana przed rozpoczęciem uczenia
- dostęp do danych:
  - **batch** - posiadamy dostęp do kompletnego zbioru danych, jeśli możemy trzymać cały zbiór danych i dane nie zmieniają się zbyt często
  - **online (mini-batches)** - karmimy model ciągle małymi porcjami danych, jeśli nie mamy miejsca na utrzymanie całego zbioru lub dane ciągle się zmieniają
- prostota (interpretowalność)
  - **White Box** - Prosty do zinterpretowania- wiemy dlaczego podjął taką a nie inną decyzję.
  - **Black Box** - Trudny do zinterpretowania- nie wiemy dlaczego podjął taką a nie inną decyzję.

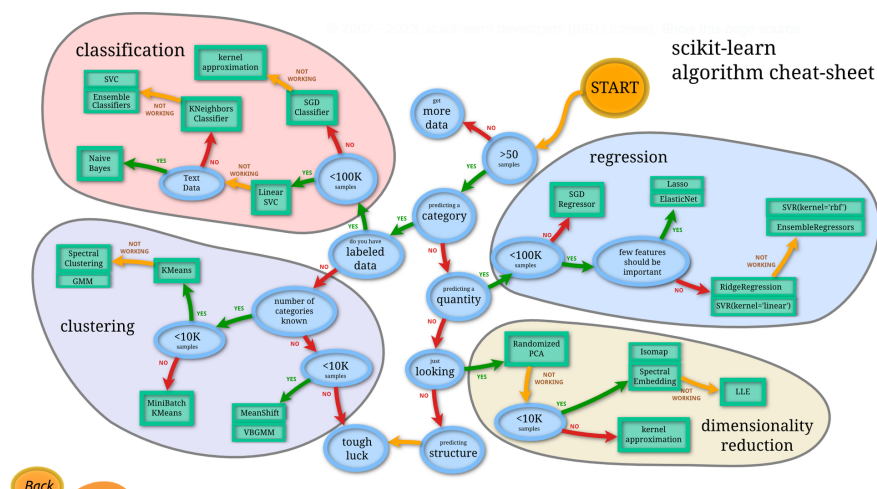


Figure 1: mapka wyboru algorytmu

## 2 Metryki

### 2.1 *Klasyfikacja*

- Confusion Matrix

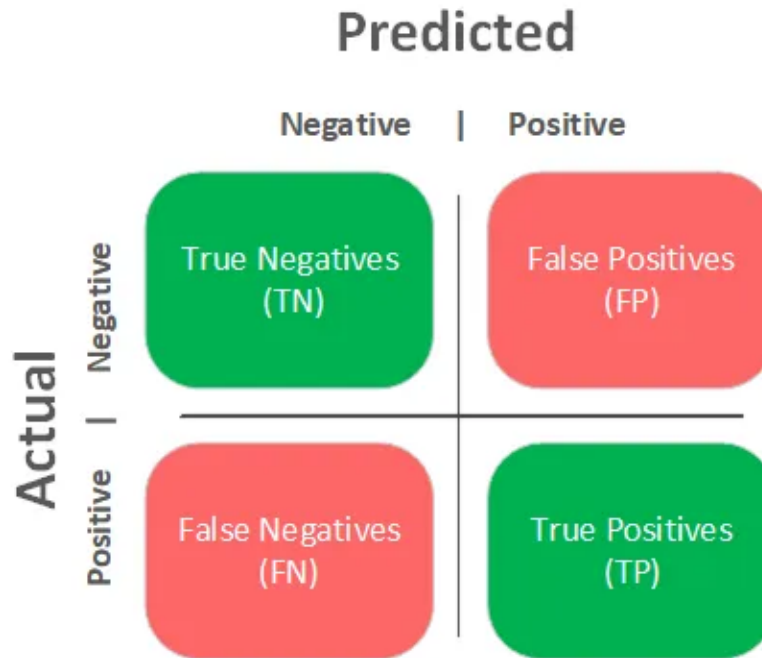


Figure 2: Confusion Matrix

#### 2.1.1 Accuracy

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

- Classification Error
  - Wyraża jaka część instancji została dobrze sklasyfikowana

#### 2.1.2 Precision

$$Precision = \frac{TP}{TP + FP}$$

- Stosowana gdy wymagamy od modelu wysoką wartość *True Positives* i chcemy zminimalizować liczbę *False Positives*
- Proporcja *True Positives* do sumy *True Positives* i *False Positives*
- W przypadku diagnozowania poważnych chorób, takich jak rak. W tym przypadku chcemy minimalizować błędne diagnozy, aby uniknąć niepotrzebnych badań i leczenia dla osób, które nie potrzebują takiej interwencji.
- Np. Jak wiele wiadomości zaklasyfikowanych jako spam faktycznie jest spamem?

### 2.1.3 Recall (True Positive Rate, Sensitivity, Probability of Detection)

$$Recall = \frac{TP}{TP + FN}$$

- Stosowana gdy wymagamy od modelu wysoką wartość *True Positives* i chcemy zminimalizować liczbę *False Negatives*
- Proporcja *True Positives* do sumy *True Positives* i *False Negatives*
- W przypadku wykrywania rzadkich chorób. Tutaj celem jest maksymalizacja liczby poprawnych diagnoz, aby zapewnić pacjentom odpowiednie leczenie w czasie.
- Np. Jak wiele wiadomości spamu zostało zaklasyfikowanych jako spam?

### 2.1.4 F1-score

$$F1-score = \frac{2}{\frac{1}{Precision} + \frac{1}{Recall}}$$

- Metryka stosowana do porównywania modeli.
- Korzystne dla modeli z podobną wartością *Precision* i *Recall*.
- Średnia harmoniczna obu wartości.

### 2.1.5 Kompromis Precision/Recall

- *Precision* zmniejsza *Recall* i vice versa.

## 2.2 Regresja

Mean square error (błąd średnio kwadratowy):

$$MSE(x, y) = \frac{1}{n} \sum_{i=1}^n (f(x_i) - y_i)^2$$

- Błąd średnio-kwadratowy, najczęściej stosowany w przypadku regresji liniowej
- Stosowana ogólnie w regresjach
- Gdy funkcja  $f$  jest różniczkowalna, to MSE jest różniczkowalny ze względu na parametry funkcji  $f$
- Równoważna z normą  $l_2$  (Norma Euklidesowa)

Mean absolute error (błąd średnio bezwzględny):

$$MAE(x, y) = \frac{1}{n} \sum_{i=1}^n |f(x_i) - y_i|$$

- Błąd średniego odchylenia wartości bezwzględnej
- Stosowana ogólnie w regres
- Stosowane gdy jest dużo *outlier'ów* w zbiorze
- Równoważna z normą  $l_1$  (Norma Manhattan)

Entropy:

$$H(X) = - \sum_{i=1}^n p(x_i) \log p(x_i)$$

- $p$  - proporcja wystąpień wartości docelowych w danych regresyjnych
- Wyraża ilość informacji, którą możemy uzyskać po otrzymaniu instancji ze zbioru
- Tworzy zbilansowane drzewa
- Tak dzielimy zbiór tworząc drzewa, aby zysk entropii był jak największy (dowiadujemy się najwięcej dzieląc w ten sposób)

Gini:

$$Gini(X) = 1 - \sum_{i=1}^n p(x_i)^2$$

- Wyraża czystość zbioru
- Szybsza do obliczenia (względem entropii, nie trzeba liczyć logarytmu)
- Ma tendencję do izolowania najczęściej występującej klasy w osobnej gałęzi drzewa.
- Jest zerowa gdy wszystkie instancje w zbiorze są tej samej klasy
- Jest maksymalna gdy instancje są równomiernie rozłożone po klasach
- Wykorzystywana w algorytmie *CART* (Classification and Regression Tree).

Entropia krzyżowa:

$$H(p, q) = - \sum_{i=1}^n p(x_i) \log q(x_i)$$

- Stosowana w klasyfikacji
- Wyraża oczekiwaną ilość informacji o instancji, jeżeli zakodujemy ją przy użyciu modelu  $q$  zamiast  $p$
- $p(x_i)$  - prawdziwy rozkład prawdopodobieństwa
- $q(x_i)$  - rozkład prawdopodobieństwa przewidywany przez model
- Podczas uczenia modelu  $q$  staramy się minimalizować entropię krzyżową, ponieważ to oznacza, że potrzebujemy mniejszej liczby bitów, żeby przewidzieć klasę instancji z rozkładu  $p$  (dla rozkładu  $p$  podczas uczenia zazwyczaj dokładnie znamy klasy każdej z instancji, więc entropia rozkładu  $p$  jest równa 0).



## 3 Regresja

### 3.1 Regresja

#### 3.1.1 Regresja Liniowa

- Opiera się na założeniu, że istnieje liniowa zależność między zmiennymi wejściowymi a zmienną wyjściową.
- Dopasowuje hiperpłaszczyznę (określoną funkcją  $g$ ), dla której średnia odległość instancji od wartości funkcji  $g$  jest najmniejsza.
- Mamy zbiór wektorów  $A \subseteq \mathbb{R}^{n+1}$  i funkcję  $f : A \rightarrow \mathbb{R}$ , która przyporządkowuje każdemu wektorowi  $x \in A$  wartość  $f(x)$
- Każdy wektor ze zbioru  $A$  ma postać  $x = [x_0, x_1, \dots, x_n]$ , gdzie  $x_0 = 1$
- Chcemy znaleźć funkcję  $g : \mathbb{R}^{n+1} \rightarrow \mathbb{R}$  taką, że  $g(x) = \Theta^T x$  dla pewnego wektora  $\Theta \in \mathbb{R}^n$  i wektor  $\Theta$  minimalizuje  $MSE(x, \Theta) = \frac{1}{n} \sum_{i=1}^n (\Theta^T x - f(x))^2$
- Można pokazać, że jeżeli mamy wektor  $z$  wszystkich wartości  $f(x)$  dla wszystkich wektorów ze zbioru  $A$  oraz  $X$  jest macierzą złożoną ze wszystkich wektorów z  $A$ , to  $\Theta = (X^T X)^{-1} X^T$

#### 3.1.2 Regresja wielomianowa

- Regresja liniowa, ale zamiast liniowej funkcji  $g$  używamy wielomianu  $g$  stopnia  $n$
- Do każdej instancji  $x$  dodajemy nowe cechy  $x_2 = x^2, x_3 = x^3, \dots, x_n = x^n$ , następnie stosujemy regresję liniową na nowym zbiorze cech.

#### 3.1.3 Regresja Logistyczna

- Wykorzystuj funkcję aktywacji  $f(x) = \frac{1}{1+e^{-x}}$  (Sigmoid)
- Szacuje prawdopodobieństwo przynależności instancji do pewnej klasy.
- Stosuje funkcji *sigmoid* do zwrócenia prawdopodobieństwa (Sigmoid zwraca wartości między 0 a 1).

## 3.2 Gradient Descent

- Stosowany jeżeli nie można znaleźć rozwiązania analitycznego (np. w przypadku regresji logistycznej), a rozważana funkcja jest ciągła i różniczkowalna w rozważanej dziedzinie
- Zaczynamy ze startowym wektorem  $x$  z dziedziny analizowanej funkcji
- Obliczamy gradient funkcji w punkcie  $x$
- Przesuwamy się w kierunku przeciwnym do wektora gradientu, ponieważ gwarantuje to najszybsze możliwe zmniejszanie się wartości funkcji
- Znajduje minimum lokalne.

#### 3.2.1 SGD Stochastic Gradient Descent:

- Stosowany w przypadku, gdy zbiór danych jest bardzo duży
- Do obliczania gradientu wybieramy losowo podzbiór danych
- Znajduje minimum lokalne, szybciej niż *Gradient Descent*, ale nie jest tak dokładny.

### 3.3 Learning Curves

#### 3.3.1 Bias

- Błąd generalizacji wynikający ze złych założeń. Prowadzi do *underfittingu*
- Model jest najprawdopodobniej zbyt prosty.

#### 3.3.2 Variance

- Nadmierna wrażliwość na małą wariancję w zbiorze danych. Prowadzi do *overfittingu*
- Model jest najprawdopodobniej zbyt skomplikowany.

#### 3.3.3 Irreducible Error

- Wynika z zaszumionego zbioru danych.

#### 3.3.4 Kompromis między *Bias* a *Variance*

- Zwiększenie złożoności modelu prowadzi do zwiększenia *Variance* i zmniejszenia *Bias*'u i vice versa.
- 

### 3.4 Regularyzowane modele liniowe

#### 3.4.1 Ridge Regression

- Regularyzowana wersja *Regresji Liniowej*
- Zmusza model do utrzymywania małych wag
- Używa normy  $l_2$

#### 3.4.2 Lasso Regression

- Regularyzowana wersja *Regresji Liniowej*
- Używa normy  $l_1$
- Ma tendencje do usuwania wag dla najmniej ważnych cech
- Zwraca *Rzadki model* (Dużo zer w polach wag)

#### 3.4.3 Early Stopping

- Zatrzymuje proces uczenia w momencie gdy *błąd walidacji* osiąga minimum.
-

## 4 SVM (Support Vector Machines)

- Algorytm klasyfikacji oparty o zasadę największego marginesu.




Figure 3: Porównanie regresji liniowej (lewy wykres) z SVM (prawy wykres)

- Wrażliwy na skalowanie danych (Zawsze skalować przed użyciem)
- 

### 4.1 Hard Margin Classification

- Wszystkie instancje muszą się znaleźć poza marginesem.
- Działa tylko wtedy, gdy dane da się liniowo rozdzielić.
- Wrażliwy na *outliers'y*

### 4.2 Soft Margin Classification

- Elastyczny model
- Szyka balansu między posiadaniem jak największego marginesu, a limitowaniem liczby jego naruszeń.

### 4.3 Nieliniowa klasyfikacja SVM


- Używaj kiedy dane nie da się rozdzielić liniowo.

#### 4.3.1 Polynomial Kernel

- Sztuczka dzięki której możemy dostać wyniki, jakbyśmy korzystali z wielomianowego modelu bez użycia go.

### 4.4 Regresor SVM

- By działał musimy odwrócić jego zadanie - zmieścić jak najwięcej instancji w jak najmniejszym marginesie.
- Model jest  $\epsilon$  niewrażliwy, czyli dodawanie więcej instancji znajdujących się w marginesie nie wpływa na zdolność przewidywania modelu.
- Do rozwiązywania nieliniowych modeli użyj **kernelized SVM model**

Figure 4: Wpływ  $\epsilon$  na wydajność regresji

## 4.5 Drzewa Decyzyjne

- Stosowany do klasyfikacji i regresji
- Nie wymaga przygotowania danych, nie trzeba skalować ani centrować
- Scikit używa algorytmu **CART** (próbując zachłannie minimalizować współczynnik Gini) do trenowania drzew decyzyjnych
- Algorytm **CART** w celu ustalenia miejsca podziału oblicza wartość  $J(k, t_k) = \frac{m_{lewa}}{m} * G_{lewa} + \frac{m_{prawa}}{m} * G_{prawa}$ , gdzie  $G_{lewa}$  i  $G_{prawa}$  wyrażają nieczystości lewej i prawej części po podziale, a  $m_{lewa}$  i  $m_{prawa}$  to liczba instancji w lewej i prawej części,  $m$  to liczba wszystkich instancji
- Obrót przestrzeni instancji może całkowicie zmieniać wygenerowane drzewo i jego złożoność.

### 4.5.1 White Box vs Black Box

- W przypadku *Black Box* ciężko jest sprawdzić dlaczego dany model podjął taką decyzję
- Dla modeli, które nie są *White Box* bardzo trudnym zadaniem jest dokładne określenie wnioskowania przeprowadzonego przez model, które może być łatwo zrozumiane przez człowieka
- Przykłady *White Box*:
  - Drzewa decyzyjne
  - Regresja Liniowa
  - SVM
- Przykłady *Black Box*:
  - Sieci neuronowe
  - Random Forests

### 4.5.2 Hiperparametry

- Bez żadnych ograniczeń model bardzo szybko przeucza się (Wtedy go nazywamy nieparametrycznym, opisany wyżej)
- **Regularyzacja** jest procesem mającym przeciwdziałać przeuczeniu, przez dobranie odpowiednich hiperparametrów

- Najważniejszą wartością jaką możemy dostrajać jest ograniczenie maksymalnej *głębokości drzewa* (Domyślnie jest  $\infty$ )

### 4.5.3 Regresja

- Struktura drzewa przypomina tą z problemu klasyfikacji.
- Możemy uznać problem regresji jako problem klasyfikacji z nieograniczoną liczbą klas, którą możemy regulować przez maksymalną głębokość drzewa.




Figure 5: Predykcje 2 regresorów o różnych maksymalnych głębokościach

## 5 Ensemble Learning i Random Forests

- Wykorzystywana jest moc przyjaźni (ang. *Power of friendship*).
- Stosujemy zasadę *mądrości tłumu* - jeżeli mamy wiele klasyfikatorów, to możemy je zagregować w grupę klasyfikatorów znacznie zwiększając wydajność modelu.
- Wszystkie klasyfikatory powinny być od siebie niezależne
- Redukuje *Bias* i *Variance*

### 5.1 W problemie klasyfikacji rozróżniamy 2 rodzaje klasyfikatorów:

#### 5.1.1 *Hard Voting Classifier*

- Wybiera klasę, która jest dominantą zbioru propozycji klas zwróconych przez klasyfikatory.

#### 5.1.2 *Soft Voting Classifier*

- Wykorzystuje prawdopodobieństwa zwracane przez model, następnie uśrednia je i wybiera klasę z najwyższym średnim prawdopodobieństwem.

### 5.2 Bagging i Pasting

- Wykorzystują wiele instancji klasyfikatora tego samego typu, ale trenowanych na różnych podzbiorach danych.
- **Bagging** (Bootstrap Aggregating) polega na losowaniu instancji ze zwracaniem (zastępowaniem) i trenowaniu na nich różnych klasyfikatorów, a następnie wykorzystaniu metody *hard voting* do wyboru klasy.
- **Pasting** jest podobny do *Bagging*'u, ale zamiast losować instancje ze zwracaniem, losuje je bez zwracania, co oznacza, że każdy klasyfikator może być trenowany tylko na części danych, a liczba klasyfikatorów jest ograniczona przez liczbę instancji w zbiorze treningowym.

### 5.3 Random Forests

- Zbiór drzew decyzyjnych
- Dodaje extra losowość
- Umożliwia łatwe sprawdzenie istotności pewnej cechy
- Jeżeli zastosujemy *Bagging* na drzewach decyzyjnych, to otrzymamy *Random Forest*
- Agreguje predykcje ze wszystkich drzew i wybiera klasę o największej ilości głosów (*hardvoting*)
  - Grupa drzew decyzyjnych
  - Każdy uczy się na innym podzbiorze zbioru danych

#### 5.3.1 *Extremely Randomized Trees Ensembly*

- Szybciej się uczy
- Stosuje losowe progi dla każdej cechy

## 5.4 Boosting

- Łączy wiele *weak learners* w *strong learner*
- Trenuje predyktory sekwencyjnie
  - Każdy kolejny próbuje poprawić błędy poprzedniego

### 5.4.1 AdaBoost

- Adaptive Boosting
- Zwraca uwagę na instancje słabo dopasowane przez poprzednie predyktory.
- Nie skaluje się dobrze.

### 5.4.2 Gradient Boosting

- Możemy go użyć z różnymi funkcjami straty
- Dopasowuje nowy predyktor do pozostałego błędu przez poprzedni model
- **XGBoost**
  - Aktualnie najlepszy klasyfikator (razem z CatBoostem).

## 5.5 Stacking

- Metoda podobna do *Voting Classifier'a*, ale zamiast używać prostych funkcji do agregacji predykcji, trenuje model, aby nauczył się jak łączyć predykcje innych modeli
- Możliwe jest stosowanie bardziej zagnieżdżonych architektur, w których występują kolejne warstwy modeli.

## 6 Redukcja Wymiarów




Figure 6: Rzutowanie danych na inną przestrzeń

- Stosujemy do uproszczenia zbioru danych w celu przyspieszenia procesu uczenia modelu
- Prowadzi do utraty części informacji, umożliwiając jednocześnie lepszą wydajność modelu
- Może być również wykorzystywana do wizualizacji danych.

### 6.1 Curse of Dimensionality

- Odnosi się do zjawiska, w którym dodanie kolejnych wymiarów do zbioru danych powoduje znaczny (eksponencjalny) wzrost wymaganej ilości danych do zachowania odpowiedniej gęstości danych.

### 6.2 PCA - Principal Component Analysis




Figure 7: PCA - Principal Component Analysis



- Jest to metoda redukcji wymiarów, w której wybieramy kierunki, które zachowują najwięcej informacji
- Kierunki te są nazywane **principal components**
- PCA znajduje kierunki, które minimalizują *średnią kwadratową odległość* między punktami danych a ich rzutami na kierunki
- Staramy się znaleźć takie kierunki, dla których występuje największa wariancja danych
- Na początku standaryzujemy dane, aby średnie wartości były równe 0
- Znajdujemy bazę przestrzeni, która jest najbardziej zbliżona do danych pod względem *średniej kwadratowej odległości* dla punktów danych i ich rzutów na bazę
- Istnieje szybszy algorytm randomizowany, który znajduje przybliżone rozwiązanie.

### 6.2.1 SVD - Singular Value Decomposition

- Jest to metoda rozkładu macierzy na iloczyn 3 macierzy
- Umożliwia wyznaczenie kierunków, które zachowują najwięcej informacji
- Stosowana w PCA
- Uogólnienie wartości własnych i wektorów własnych na macierze niekwadratowe
- Największe wartości singularne odpowiadają kierunkom, które zachowują najwięcej informacji.

## 6.3 Incremental PCA

- minibatch, out-of-core, praca na strumieniach, trzeba podać liczbę wymiarów
- Czyli w sumie po prostu PCA na online(minibatches), gdzie nie ładujemy całego zestawu danych na raz do modelu

## 6.4 Rozmaitości

- Są to zbiory danych, które mogą być zredukowane do mniejszej liczby wymiarów, ale nie muszą być przestrzeniami liniowymi
- W małej skali wyglądają jak przestrzenie liniowe, ale w większej skali mogą mieć kształty przeróżne
- Zastosowanie dla nich algorytmu PCA może prowadzić do zbyt intensywnej utraty informacji
- Istnieją algorytmy, które pozwalają na redukcję wymiarów dla takich zbiorów danych.

### 6.4.1 LLE - Locally Linear Embedding

- Algorytm ten znajduje lokalne zależności między punktami danych, a następnie próbuje zachować te zależności w niższej wymiarowości
- Jest to algorytm nienadzorowany
- Może prowadzić do zniekształcenia danych w dużej skali
- W pierwszym kroku znajduje najbliższych sąsiadów dla każdego punktu danych
- Następnie znajduje wagi, które pozwalają na rekonstrukcję każdego punktu danych jako kombinacji liniowej jego najbliższych sąsiadów
- W ostatnim kroku rzutuje dane na przestrzeń o niższej wymiarowości, zachowując lokalne zależności.




Figure 8: Rozmaitość - przykład Swiss Roll




Figure 9: Swiss Roll po zastosowaniu LLE

## 7 Uczenie nienadzorowane

Kategorie uczenia nienadzorowanego:

- Klasteryzacja *clustering*
  - identyfikacja klas
  - redukcja wymiarów
  - analiza danych (po klasteryzacji, dla każdej klasy osobno)
  - uczenie częściowo nadzorowane
  - segmentacja obrazu, detekcja, kompresja
- Detekcja anomalii
  - detekcja wartości odstających, *outlierów*
- Estymacja gęstości *density estimation*




Figure 10: Różnica między uczeniem nadzorowanym a nienadzorowanym

### 7.1 Soft Clustering

- Przypisuje każdej instancji wynik przypisywany dla każdego klastra.
  - Wynikiem może być np. dystans pomiędzy instancją a centroidą.

### 7.2 Hard Clustering

- Każda instancja jest przypisana do 1 klastra.

### 7.3 DBSCAN

- Algorytm DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*) jest algorytmem klasteryzacji, który znajduje skupiska o wysokiej gęstości
- Algorytm ten znajduje skupiska o wysokiej gęstości, a także punkty odstające
- Algorytm ten nie wymaga określenia liczby klastrów
- Wymaga określenia dwóch parametrów: *eps* i *min\_samples*
  - *eps* - maksymalna odległość między dwoma punktami, aby zostały one uznane za sąsiadów
  - *min\_samples* - minimalna liczba punktów, aby uznać je za rdzeń (wliczając w to punkt, dla którego szukamy sąsiadów)

- Wszystkie instancje, które nie są rdzeniami, ale mają sąsiadów, są uznawane za brzegi, wchodzą w skład tego samego klastra, co ich rdzeń
- Instancje, które nie są ani rdzeniami, ani brzegami, są uznawane za anomalią (nie należą do żadnego klastra)

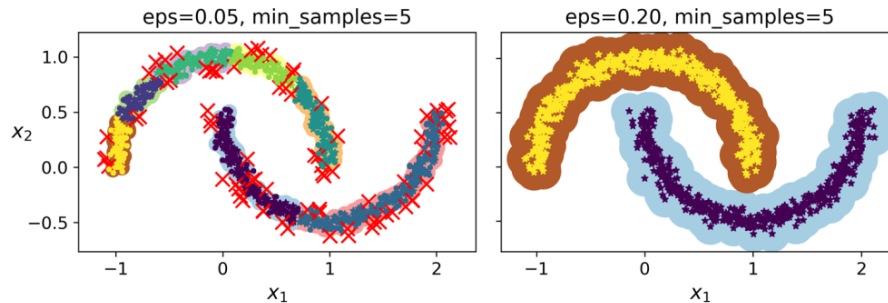


Figure 11: Przedstawienie działania alg. DBSCAN

## 7.4 KNN - K-nearest neighbors

- Algorytm KNN (*K-nearest neighbors*) jest algorytmem klasyfikacji, który przypisuje nową instancję do klasy, która jest najbardziej popularna wśród  $k$  najbliższych sąsiadów
- W przypadku regresji algorytm ten zwraca średnią wartość  $k$  najbliższych sąsiadów
- Jeżeli  $k$  jest zbyt małe, to algorytm ten jest podatny na szumy
- W przypadku remisu:
  - wybór pierwszej napotkanej instancji (implementacja scikit-learn)
  - wybór losowy
  - wybór liczniejszej klasy
  - wybór wartości najbliższej instancji (tylko dla regresji)
  - brana pod uwagę jest odległość od instancji do sąsiada (średnia ważona) (tylko dla regresji)
  - średnia wartość wszystkich instancji o tej samej odległości (tylko dla regresji)

## 7.5 Algorytm centroidów (k-średnich) *K-Means*

- Algorytm centroidów (k-średnich) *K-Means* jest jednym z najpopularniejszych algorytmów klasteryzacji.
- Algorytm stara się znaleźć środek każdego z  $k$  skupisk
- Algorytm ten przypisuje każdy punkt danych do najbliższego centroidu, a następnie przesuwa centroidy tak, aby minimalizować średnią kwadratową odległość między punktami danych a ich centroidami
- $k$  jest parametrem algorytmu, który musi zostać określony przez użytkownika
- Jest zbieżny
- Nie gwarantuje znalezienia optimum (zależy od kroku 1)
  - Domyślnie algorytm uruchamiany jest 10 razy
  - Wybierany jest model z najmniejszą **inercją**: średnio-kwadratowa odległość między instancjami i ich centroidami




Figure 12: Przedstawienie działania alg. KNN

- \* zmierz odległość między instancjami a ich centroidami
- \* zsumuj kwadraty w/w odległości w ramach klastra
- \* zsumuj wartości inercji dla wszystkich klastrów
- Przedstawieniem wyniku działania algorytmu jest Diagram Woronoja *Voronoi*
- *K-Means++*
  - Nowsza wersja
  - W bardziej optymalny sposób dobiera początkowe centroidy
- *Mini batch K-Means*
  - Używa *batch* zamiast całego zbioru danych
- W przypadku równej odległości do więcej niż jednego centroida instancja jest przypisywana do **losowego centroidu**, pierwszego napotkanego centroidu lub wybierany jest centroid grupujący większą liczbę instancji





Figure 13: Przykładowy rozkład danych

Figure 14: Diagram Woronoja *Voronoi* wyznaczony przez alg. K-Means

### 7.5.1 Wyznaczanie liczby klastrow

Do wyznaczenia liczby klastrow nie wystarcza sama inercja, ponieważ maleje ona wraz ze zwiększaniem się liczby klastrow.






Figure 15: Przykład podziału na niepoprawną liczbę klastrow

**Inercja** nie wystarcza, ale można ją wykorzystać. Wystarczy wyznaczyć inercję dla różnych wartości  $k$  i wybrać tę, która jest na ‘zgięciu’ wykresu.

Do wyznaczenia liczby klastrow możemy również wykorzystać **Wskaźnik sylwetkowy**, *silhouette score*. Wskaźnik bierze pod uwagę średnią odległość pomiędzy obserwacjami wewnątrz grupy ( $a_i$ ) i średnią odległość pomiędzy obserwacjami do najbliższej “obcej” grupy ( $b_i$ ) i dany jest wzorem:

$$s = \frac{1}{k} \sum_{i=1}^k \frac{a_i - b_i}{\max(a_i, b_i)}$$

- Najlepsza wartość: 1
- Najgorsza wartość: -1
- Nakładające się wartości: w pobliżu 0

Figure 16: Wykorzystanie inercji do wyznaczenia liczby  $k$ Figure 17: Wykorzystanie wskaźnika sylwetkowego do wyznaczenia liczby  $k$ 

## 8 Sieci neuronowe - wprowadzenie

### 8.1 Perceptron

- Składają się z jednej warstwy neuronów
- Każdy neuron jest jednostką liniową, po której następuje funkcja aktywacji
- Sposób działania:
  - oblicz sumę wejść  $z = w_1x_1 + w_2x_2 + \dots + w_nx_n = x^T w$
  - zastosuj funkcję schodkową:  $h_w(x) = \text{step}(z)$
- Ograniczenia:
  - Nie potrafią rozwiązać pewnych trywialnych problemów, np. XOR. W takich przypadkach stosuje się **sieci wielowarstwowe (MLP)**

#### 8.1.1 Uczenie perceptronu

- Uczenie perceptronu polega na znalezieniu wektora wag  $w$ , który pozwoli na poprawne sklasyfikowanie jak największej liczby instancji
- Wagi są aktualizowane na podstawie błędu predykcji według wzoru  $w_{i,j}^{(\text{nastpna iteracja})} = w_{i,j} + \eta(y_j - \hat{y}_j)x_i$ 
  - $w_{i,j}$  - waga połączenia między neuronem  $i$  a neuronem  $j$
  - $\eta$  - współczynnik uczenia

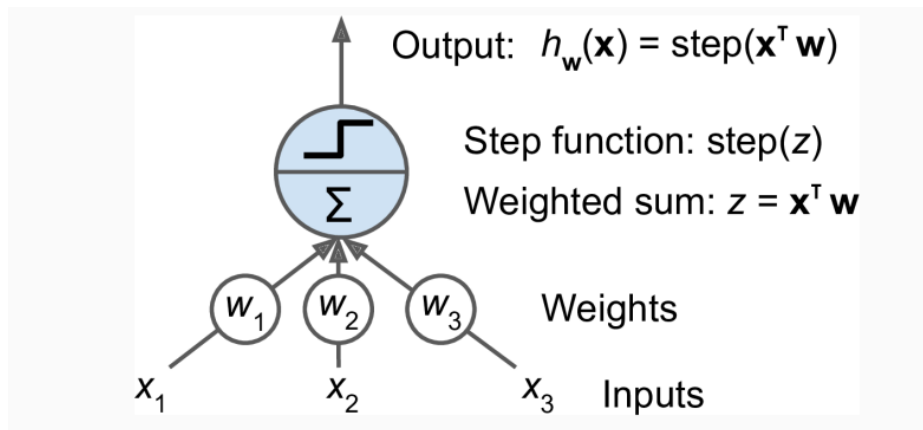


Figure 18: Alt text

- $y_j$  - wartość oczekiwana
- $\hat{y}_j$  - wartość przewidziana
- $x_i$  - wartość wejścia

## 8.2 Funkcje aktywacji

### 8.2.1 Dlaczego potrzebujemy funkcji aktywacji?

- Konieczność nieliniowości
  - Jeżeli używamy liniowych funkcji aktywacji, to kilka nałożonych na siebie warstw jest równoważna z jedną warstwą.
  - Sieć neuronowa będzie zachowywać się jak jedna warstwa neuronów (dla macierzy  $W_1$  i  $W_2$  będzie można znaleźć macierz  $W$ , która będzie równoważna działaniu sieci neuronowej,  $W = W_2 W_1$ )
- Potrzebujemy dobrze zdefiniowanej niezerowej pochodnej
  - *Gradient Descent* robi progres w każdym kroku.

Poniższa lista jest ułożona od najlepszych funkcji aktywacji (oprócz **softmax**).

#### 1. SeLU (Skalowana liniowa jednostka eksponencjalna)

- Najlepsze dla *Głębokiej Sieci Neuronowej*
- Potrafi się samodzielnie znormalizować
  - Rozwiązuje problem znikających i eksplodujących gradientów.
- Warunki zbioru danych:
  - Wszystkie warstwy muszą być gęste
  - Dane muszą być standaryzowane (średnia = 0, odchylenie standardowe = 1).

$$SeLU(z) = \begin{cases} \lambda \alpha (e^z - 1) & \text{if } z < 0 \\ \lambda z & \text{if } z \geq 0 \end{cases}$$

#### 2. ELU (Exponential Linear Unit):



- ELU jest podobne do SeLU, ale nie jest zależne od normalizacji danych.
- Funkcja ELU ma mniejszą podatność na problem znikających i wybuchających gradientów.

$$ELU(z) = \begin{cases} \alpha(e^z - 1) & \text{if } z < 0 \\ z & \text{if } z \geq 0 \end{cases}$$

### 3. Leaky ReLU

- Leaky ReLU jest modyfikacją funkcji ReLU, która rozwiązuje problem “martwych neuronów” (neurony, które zawsze mają wartość 0 dla niektórych danych wejściowych).

$$LeakyReLU(z) = \max(\alpha z, z)$$

### 4. ReLU (Rectified Linear Unit):

- ReLU jest jedną z najpopularniejszych funkcji aktywacji. Ma dobrą zdolność do modelowania nieliniowych relacji.
- Jeżeli wszystkie wartości danych treningowych są ujemne, to neuron z ReLU się nie uczy

$$ReLU(z) = \max(0, z)$$

### 5. Tanh (tangens hiperboliczny):

- Funkcja tanh jest splotem funkcji sigmoidalnej i może generować wartości z przedziału  $(-1, 1)$ .
- Funkcja ta ma symetryczny kształt wokół zera i może być przydatna w przypadkach, gdy oczekuje się zarówno wartości dodatnich, jak i ujemnych.

$$\tanh(z) = 2\sigma(2z) - 1$$

### 6. logistic (funkcja sigmoidalna):

- Funkcja sigmoid, znana również jako funkcja logistyczna, generuje wartości z przedziału  $(0, 1)$ .
- Często jest używana w warstwie wyjściowej modeli binarnych do przewidywania prawdopodobieństwa przynależności do jednej z dwóch klas.

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

### 7. Softmax


- Funkcja aktywacji wykorzystywana w warstwie wyjściowej klasyfikatorów wieloklasowych, generuje rozkład prawdopodobieństwa.
- Opisuje pewność dopasowania do każdej klasy.

$$Softmax(z)_j = \frac{e^{z_j}}{\sum_{k=1}^K e^{z_k}}$$

## Activation Functions


### Sigmoid

$$\sigma(x) = \frac{1}{1+e^{-x}}$$




### Leaky ReLU

$$\max(0.1x, x)$$



### tanh

$$\tanh(x)$$




### Maxout

$$\max(w_1^T x + b_1, w_2^T x + b_2)$$

### ReLU

$$\max(0, x)$$



### ELU

$$\begin{cases} x & x \geq 0 \\ \alpha(e^x - 1) & x < 0 \end{cases}$$




Figure 19: Wykresy omawianych funkcji aktywacji

## 8.3 Warstwy

### 8.3.1 Warstwa gęsta

- Każdy neuron jest połączony z każdym neuronem z poprzedniej warstwy
- Wagi połączeń są zapisane w macierzy wag  $W^*$
- Każdy neuron ma dodatkowy parametr  $b$ , który jest nazywany *biasem* - w innym przypadku dla wektora zerowego na wejściu, na wyjściu otrzymalibyśmy wektor zerowy (jeżeli funkcja aktywacji ma punkt stały w 0)

## 9 Głębokie sieci neuronowe

Głębokie sieci neuronowe (DNN - Deep Neural Networks) to sieci neuronowe z wieloma warstwami ukrytymi

### 9.1 Budowa modelu

#### 9.1.1 Keras Sequential API

- Najprostszy sposób tworzenia sieci neuronowej
- Zakłada, że sieć jest sekwencją warstw
- Warstwy dodajemy jako instancje odpowiednich klas z pakietu `keras.layers`
- parametr można przekazywać jako ciągi znaków. Jest to zapis uproszczony: zamiast "relu" można przekazać `keras.activations.relu`
- Normalizację danych można wykonać za pomocą warstwy `keras.layers.Normalization`, lub `keras.layers.Flatten`, albo zrobić samemu wcześniej

```
import tensorflow as tf

model = tf.keras.Sequential([
    tf.keras.layers.Flatten(input_shape=[28, 28]),
    tf.keras.layers.Dense(300, activation="relu"),
    tf.keras.layers.Dense(100, activation="relu"),
    tf.keras.layers.Dense(10, activation="softmax")
])
```

#### 9.1.2 Keras Functional API

- Pozwala na tworzenie bardziej skomplikowanych architektur sieci neuronowych
- Pozwala na tworzenie grafów obliczeniowych, w których nie wszystkie warstwy są połączone ze sobą w sekwencji
- Pozwala na tworzenie wielu modeli, które mają współdzielone warstwy
- Do tworzenia modelu wykorzystujemy klasę `tf.keras.Model`, podaje się w niej warstwy wejściowe i wyjściowe
- Do tworzenia warstw wykorzystujemy klasę `tf.keras.layers`, podobnie jak w przypadku Sequential API
- Łączenie warstw odbywa się za pomocą operatora `(warstwa)(wejście)`, podobnie jak w przypadku wywoływania funkcji, co oznacza, że warstwa jest wywoływana na wejściu otrzymanym z poprzedniej warstwy będącej argumentem wywołania

```
import tensorflow as tf

input_ = tf.keras.layers.Input(shape=[28, 28])
flatten = tf.keras.layers.Flatten(input_shape=[28, 28])(input_)
```

```
hidden1 = tf.keras.layers.Dense(300, activation="relu")(flatten)
hidden2 = tf.keras.layers.Dense(100, activation="relu")(hidden1)
concat = tf.keras.layers.Concatenate()([input_, hidden2])
output = tf.keras.layers.Dense(10, activation="softmax")(concat)
model = tf.keras.Model(inputs=[input_], outputs=[output])
```

## 9.2 Kompilacja i uczenie modelu

Po utworzeniu modelu należy go skompilować za pomocą metody `compile()`. Metoda ta przyjmuje następujące parametry:

- **optimizer**: Określa **optymalizator** używany do aktualizacji wag modelu podczas procesu uczenia. Optymalizator reguluje sposób, w jaki model aktualizuje wagi na podstawie straty i algorytmu optymalizacji. Ich argumentem jest m.in. `learning_rate`. Przykładowe optymalizatory:
  - **SGD** - Stochastic Gradient Descent
  - **Momentum** - SGD z pędem
  - **Nesterov Accelerated Gradient** - SGD z pędem Nesterova
    - \* Szybka zbieżność
    - \* Minimalnie szybsza od *Momentum*
  - **AdaGrad** - Adaptive Gradient, nie wykorzystuje pędu, ale dostosowuje współczynnik uczenia dla każdego parametru na podstawie jego historii aktualizacji
    - \* Działa dobrze dla prostych problemów kwadratowych
    - \* Ryzyko nie osiągnięcia minimum
  - **Adam** - Adaptive Moment Estimation, wykorzystuje pęd i historię aktualizacji
    - \* Wariacje *Adam*:
      - **Nadam** (Adam + Nesterov) - Generalnie jest lepsza od *Adam*
  - **RMSProp** - Zbiera gradienty tylko z najwcześniejszych iteracji
    - \* Wiele lepszy niż *AdGrad*
    - \* **Problemy Adaptive estimation methods**
      - M. in. Adam, Nadam, RMSProp, Adagrad
      - Mogą źle generalizować zbiory danych
      - Jak są jakieś problemy użyj *Nesterov Accelerated Gradient*
- **loss**: Określa **funkcję straty**, która jest używana do oceny odchylenia między przewidywaniami modelu a rzeczywistymi wartościami. Przykładowe funkcje straty to ‘mean\_squared\_error’, ‘categorical\_crossentropy’, ‘binary\_crossentropy’ itp. Wybór odpowiedniej funkcji straty zależy od rodzaju problemu i rodzaju wyjścia modelu.
- **metrics**: Określa **metryki**, które będą używane do oceny wydajności modelu. Przykładowe metryki to ‘accuracy’, ‘precision’, ‘recall’, ‘mean\_absolute\_error’ itp. Metryki służą do monitorowania wydajności modelu podczas uczenia i ewaluacji.
- Inne opcjonalne argumenty, takie jak `loss_weights`, `sample_weight_mode`, `weighted_metrics`, które pozwalają na bardziej zaawansowane konfigurowanie procesu kompilacji modelu.

```
model.compile(loss="adam",
              optimizer="sgd",
              metrics=["accuracy"])
```

A następnie wytrenować model za pomocą metody `fit()`. Metoda ta przyjmuje następujące parametry:

- **x**: **Dane wejściowe** do modelu.
- **y**: **Dane wyjściowe** (etykiety) odpowiadające danym wejściowym x.
- **batch\_size**: Określa liczbę próbek, które są przetwarzane jednocześnie przez model w trakcie jednej iteracji.
- **epochs**: Określa liczbę **epok uczenia** - pełnych przebiegów przez zbiór treningowy. Każda epoka oznacza jedno przejście przez cały zbiór treningowy.
- **validation\_data**: **Dane walidacyjne** używane do oceny wydajności modelu na każdej epoce. Może to być krotka (x\_val, y\_val) zawierająca dane wejściowe i oczekiwane wyjście dla danych walidacyjnych.
- **callbacks**: Lista obiektów zwrotnych (callbacks), które są wywoływane podczas treningu w różnych momentach. Przykłady to ModelCheckpoint, EarlyStopping, TensorBoard itp. Callbacks pozwalają na dostosowywanie zachowania treningu w zależności od określonych warunków.
- **verbose**: Określa tryb wyświetlania informacji podczas treningu. Może przyjąć wartość 0 (bez wyświetlania), 1 (wyświetlanie paska postępu) lub 2 (wyświetlanie jednej linii na epokę).
- Inne opcjonalne argumenty, takie jak `validation_split`, `shuffle`, `class_weight` itp., które pozwalają na bardziej zaawansowane konfigurowanie procesu treningu modelu.

```
history = model.fit(
    X_train,
    y_train,
    batch_size=32,
    epochs=10,
    validation_data=(X_valid, y_valid),
    callbacks=[early_stopping_cb],
    verbose=1
)
```

### 9.3 Callbacks

Callbacks pozwalają na wykonywanie dodatkowych operacji w trakcie uczenia modelu. Użyteczne jak mamy długi czas uczenia. Przykładowe callbacki ich zastosowania:

- **ModelCheckpoint** - Zapisywanie punktów kontrolnych
- **EarlyStopping** - zatrzymanie uczenia, jeżeli nie nastąpi poprawa wyniku przez 10 epok (bardzo częste zastosowanie)

- TensorBoard - zapisywanie logów do wykorzystania w TensorBoard

```
checkpoint_cb = keras.callbacks.ModelCheckpoint(
    "my_keras_model.h5",
    save_best_only=True
)

early_stopping_cb = keras.callbacks.EarlyStopping(
    patience=10,
    restore_best_weights=True
)

tensorboard_cb = keras.callbacks.TensorBoard(
    log_dir="./my_logs",
    histogram_freq=1,
    profile_batch=100
)
```

Callbacki dodajemy w parametrze `callbacks` metody `fit`.

## 9.4 Analiza procesu uczenia




Figure 20: Wykres wartości miar w trakcie procesu uczenia

- **Loss** - miara, która określa, jak bardzo wyniki modelu różnią się od oczekiwanych wartości.
- **Accuracy** - miara, która określa, jak dokładnie model przewiduje klasy lub etykiety dla danych.
- **Recall** - miara, która określa, jak wiele pozytywnych przypadków zostało wykrytych przez model.
- **Precision** - miara, która określa, jak wiele pozytywnych przypadków zostało poprawnie określonych

przez model.

- ***Val\_loss*** - strata obliczana na danych walidacyjnych, służy do monitorowania uczenia modelu i unikania przeuczenia.
- ***Val\_accuracy*** - dokładność obliczana na danych walidacyjnych, pomaga ocenić, jak dobrze model generalizuje na nowych danych.

Przykłady funkcji strat zostały przedstawione na początku dokumentu.




Figure 21: Loss

## 9.5 Przeszukiwanie przestrzeni hiperparametrów

### 9.5.1 SciKit-Learn

- **RandomizedSearchCV** - losowe przeszukiwanie przestrzeni hiperparametrów
  - Lepsze od GridSearch
- **GridSearchCV** - przeszukiwanie przestrzeni hiperparametrów siatką wartości parametrów
  - Wydajny gdy funkcja jest szybka w obliczeniu. (Model mało skomplikowany)
- Jak mamy bardziej złożony model to polecam bibliotekę *Optuna*

### 9.5.2 Keras Tuner

- **RandomSearch** - losowe przeszukiwanie przestrzeni hiperparametrów

## 10 Konwolucyjne sieci neuronowe

- Konwolucyjne sieci neuronowe (CNN - Convolutional Neural Networks)
- CNN są stosowane do przetwarzania wielowymiarowych danych, takich jak obrazy, wideo itp.
- Wykorzystują specjalny rodzaj warstwy zwanej warstwą konwolucyjną (Convolutional Layer), która wykonuje operację konwolucji na danych wejściowych.
- Wymagają mniejszej liczby parametrów (względem *DNN*).
- Rozbijamy większy problem (np. rozpoznawanie obrazów) na mniejsze prostsze problemy (np. wykrywanie krawędzi).

### 10.1 Konwolucja

- Struktura Hierarchiczna.
- Zamiast 1 wielkiej warstwy używamy wielu tych samych, małych liniowych warstw w każdej pozycji.
- koncentruje się na niskopoziomowych cechach w początkowych ukrytych warstwach, w kolejnej warstwie agreguje je do większej wysokopoziomowej cechy.
- Konwolucja to operacja matematyczna, która łączy dwa zestawy danych za pomocą funkcji matematycznej, aby wygenerować trzeci zestaw danych.
- W przypadku konwolucyjnych sieci neuronowych operacją konwolucji jest iloczyn skalarny (mnożenie element-wise) dwóch zestawów danych.
- Konwolucja jest operacją liniową, która może być używana do wielu celów, takich jak wykrywanie krawędzi i innych wzorców w obrazach, wykrywanie cech w danych itp.
- Polega na wykonywaniu sum ważonych dla fragmentów funkcji wejściowej ważonej przez jądro (kernel, który jest macierzą wag).
- W przypadku sieci neuronowych dane wejściowe są zwykle macierzą wielowymiarową (np. obrazem) i są one łączone z macierzą wag (kernel), aby wygenerować macierz wyjściową
- Wagi są parametrami, które są uczone podczas treningu modelu
- W przypadku obrazów macierz wejściowa zawiera piksele obrazu, a macierz wag zawiera filtry, które są aplikowane na obrazie
- Konwolucja może być obliczana na całym obrazie, ale zwykle stosuje się ją tylko do fragmentu obrazu, aby uzyskać macierz wyjściową o takich samych wymiarach jak macierz wejściowa
- W przypadku obrazów wagi są zwykle małymi macierzami o wymiarach 3x3 lub 5x5. W przypadku obrazów kolorowych, które mają 3 kanały kolorów (RGB), macierz wag ma wymiary 3x3x3 lub 5x5x3.
- Każda warstwa konwolucyjna składa się z wielu filtrów, które są stosowane do danych wejściowych, aby wygenerować różne macierze wyjściowe w celu wykrycia różnych cech w danych wejściowych

### 10.2 Typowe błędy podczas projektowania CNN

- Stosowanie za dużych jąder konwolucji (Wyjątek: Pierwsza warstwa konwolucyjna)
  - Zamiast tego nałóż więcej mniejszych warstw
    - \* Prowadzi to do mniejszej liczby parametrów i mniejszej liczby obliczeń.






Figure 22: Przykład prostej sieci konwolucyjnej

### 10.3 Pooling

- Pooling neuron nie posiada wagi
  - Jej celem jest agregacja wejść korzystając z funkcji *max* lub *mean*.
- Pooling jest operacją, która zmniejsza wymiary danych wejściowych poprzez zastąpienie fragmentu danych wejściowych pojedynczą wartością reprezentującą ten fragment zwracaną przez sprecyzowaną wcześniej funkcję
- Najczęściej stosowaną funkcją agregującą jest funkcja *max*, która zwraca maksymalną wartość w fragmencie danych wejściowych
- Pozwala kolejnym warstwom sieci na wykrywanie cech bardziej ogólnych, poprzez zwielokrotnienie obszaru, na którym bezpośrednio działają
- Często stosowany po warstwie konwolucyjnej, aby zmniejszyć wymiary danych wejściowych
- Najczęściej zmniejsza każdy wymiar danych wejściowych o połowę.

### 10.4 Dropout

- Sprawia, że wielka sieć działa jak mniejsza losowo trenując podsekcje sieci.
  - *Mniejsze sieci neuronowe nie mają skłonności do przeuczenia*
- Dropout jest techniką regularyzacji, która losowo wyłącza neurony podczas uczenia
- Pomaga w zapobieganiu przeuczeniu modelu.

### 10.5 Uczenie rezydualne (Residual Learning)

- Residual Learning jest techniką uczenia głębokich sieci neuronowych, która skupia się na uczeniu różnic (residuum) pomiędzy wartością rzeczywistą a przewidywaną
- Residual Learning pomaga w zapobieganiu zanikaniu gradientu (*vanishing gradient*) i przyspiesza proces uczenia modelu

- Wykorzystujemy obejście (skip connection), aby dodać dane wejściowe do danych wyjściowych warstwy, aby uzyskać dane wyjściowe warstwy rezydualnej.
  - Sieć zaczyna robić progres nawet kiedy niektóre warstwy sieci nie zaczęły procesu uczenia.

## 10.6 Klasyfikacja i Lokalizacja obiektów

- Lokalizacja obiektów jest techniką uczenia głębokich sieci neuronowych, która służy do wykrywania obiektów w konkretnej lokalizacji na obrazie
- Można wykorzystać sieci w pełni konwolucyjne (Fully Convolutional Networks) do lokalizacji obiektów, wtedy każdy element wyjściowej macierzy reprezentuje prawdopodobieństwo wystąpienia obiektu w określonym obszarze obrazu
- Inną metodą jest wykorzystanie przesuwanego okna (sliding window), która polega na przesuwaniu okna po obrazie i sprawdzaniu, czy w oknie znajduje się obiekt, wymaga to wielokrotnego przetwarzania obrazu, co jest bardzo kosztowne obliczeniowo oraz różnych rozmiarów okna, aby wykryć obiekty o różnych rozmiarach

### 10.6.1 Bounding Boxes

- Sieci takie nazywamy *Region Proposal Network*.
- Gdy zaklasyfikujemy pewien obiekt i chcemy go zlokalizować na obrazie stosujemy *Bounding Boxes* czyli określamy prostokątem fragment obrazu w którym najprawdopodobniej znajduje się obiekt.
- *non-max suppression*
  - Usuwamy nadmierną detekcje tego samego obiektu.




Figure 23: Wizualizacja wyniku działania non-max suppression

### 10.6.2 Fully Convolutional Networks

- Może być przećwiczona i użyta dla obrazów dowolnej wielkości

### 10.6.3 YOLO You Only Look Once

- Szybkie i dokładne
- Działa w czasie rzeczywistym

#### 10.6.4 *Transponowana warstwa konwolucyjna (Transposed Convolutional Layer)*

- Może wykonywać interpolację liniową
- Warstwa którą możemy trenować
- Rozciąga zdjęcia przez dodawanie pustych wierszy i kolumn

#### 10.6.5 Segmentacja semantyczna

- Segmentacja semantyczna jest problemem, który polega na przypisaniu każdemu pikselowi obrazu etykiety, która reprezentuje klasę, do której należy dany piksel
- Można w tym celu stosować architekturę U-Net, która składa się z warstw konwolucyjnych, warstw poolingowych i warstw dekonwolucyjnych tworzącą symetryczną strukturę w kształcie litery U.
- Różne obiekty tej samej klasy nie są rozróżnialne.

#### 10.6.6 Metryki:

- *Mean Average Precision*
- *Intersection over Union*
  - Sprawdza jak dobrze model przewiduje *pola ograniczające* (bounding boxes).

## 11 Rekurencyjne sieci neuronowe

- Rekurencyjne sieci neuronowe (RNN - Recurrent Neural Networks)
- RNN są stosowane do przetwarzania sekwencyjnych danych, takich jak tekst, dźwięk, czasowe serie danych itp.
- Wykonują przewidywania dla sekwencji o dowolnej długości.
- Często wykorzystywane do predykcji na podstawie sekwencji danych wejściowych (o dowolnej długości), najczęściej do przewidywania przyszłości.
- Wykorzystują specjalny rodzaj warstwy zwanej warstwą rekurencyjną (Recurrent Layer), która przechowuje stan wewnętrzny, który jest aktualizowany za każdym razem, gdy warstwa otrzymuje dane wejściowe.
- Sieć wykonuje tę samą operację na każdym elemencie sekwencji, po czym agreguje informacje poprzednich wyrażen w celu przewidzenia następnego.
- Zastosowania: finanse (giełda), pojazdy autonomiczne, sterowanie, wykrywanie usterek
- *Dużą wadą są znikające i eksplodujące gradienty*
  - gradient  $\approx 0$  lub zmieża do  $\infty$ .
- Gdy sekwencja danych jest bardzo długa, sieć zapomina początkowe wartości

Podstawowym elementem RNN jest komórka rekurencyjna, która ma stan wewnętrzny przechowujący informacje z poprzednich **kroków czasowych (ramek)**. W każdym kroku czasowym komórka otrzymuje dane wejściowe oraz stan wewnętrzny (z poprzedniego kroku) i generuje nowy stan wewnętrzny oraz dane wyjściowe. Ten proces jest powtarzany dla każdego kroku czasowego.

Istnieje kilka różnych typów RNN, takich jak **SimpleRNN**, **LSTM** (Long Short-Term Memory), **GRU** (Gated Recurrent Unit) i **Bidirectional RNN**, które różnią się w sposobie zarządzania i aktualizacji stanu wewnętrznego. Na przykład, LSTM wprowadza bramki, które kontrolują przepływ informacji, pozwalając na efektywne uczenie się zależności na różnych skalach czasowych i unikanie problemu zanikającego gradientu.

### 11.1 Rodzaje RNN ze względu na rodzaj danych wejściowych/wyjściowych

#### 11.1.1 Sequence to sequence network

Pobiera sekwencje danych wejściowych i generuje sekwencję przewidywanych danych.

#### 11.1.2 Vector to sequence network (Dekoder)

Podaje ten sam wektor danych wejściowych w każdym kroku czasowym i generuje sekwencję przewidywanych danych.

#### 11.1.3 Sequence to vector network (Enkoder)

Podaj sekwencję danych wejściowych i zignoruj wygenerowaną sekwencję przewidywanych danych poza ostatnią wartością.

## 11.2 Działanie RNN w kilku krokach:

- Dane wejściowe sekwencyjne są podzielone na kroki czasowe.
- Na każdym kroku czasowym, dane wejściowe są przetwarzane przez komórkę rekurencyjną, która aktualizuje swój stan wewnętrzny.
- Dane wyjściowe są generowane na podstawie aktualnego stanu wewnętrznego.
- Proces jest powtarzany dla kolejnych kroków czasowych, przekazując informacje z poprzednich kroków.

## 11.3 Przewidywanie kilku kroków czasowych do przodu

Rozróżniamy 3 najpopularniejsze sposoby:

- Model przewiduje 1 krok czasowy na raz: Wyjście modelu prowadzimy do wejścia modelu. Jest to najgorsza opcja, błąd jest akumulowany za każdym cyklem.
- Model przewiduje  $n$  kroków na raz
- Model przewiduje wszystkie kroki na raz: Najlepsza opcja

## 11.4 Unrolling (rozwijanie)

Proces rozwinięcia lub dekompresji sieci rekurencyjnej na wielu krokach czasowych. W standardowej definicji RNN, model jest reprezentowany jako powtarzające się jednostki, które operują na danych wejściowych w każdym kroku czasowym. Jednak w celu lepszego zrozumienia i wizualizacji działania sieci, często stosuje się unrolling.

Podczas unrollingu, sieć rekurencyjna jest rozwinięta wzdłuż osi czasu, tworząc sekwencję powiązanych ze sobą jednostek. Każda jednostka reprezentuje stan wewnętrzny (np. LSTM lub GRU) oraz warstwę wyjściową, która otrzymuje dane wejściowe z danego kroku czasowego i generuje dane wyjściowe dla tego kroku. Te powiązane jednostki są połączone ze sobą, przechodząc informacje z jednego kroku czasowego do drugiego.

## 11.5 Osadzenia

Dokładnie reprezentują ciągi o zmiennej długości przez wektory o stałej długości.

## 11.6 Rozwiązanie problemu niestabilnych gradientów

- Użyj tych samych rozwiązań co w przypadku *DNN*
- Nie stosuj nienasyconych funkcji aktywacji
  - np. ReLU
- *Batch Normalization* nie jest przydatne
  - Jak już musisz to stosuj pomiędzy warstwami rekurencyjnymi
- *Layer Normalization*

## 12 Porównania

### 12.1 Modele

Poniżej znajduje się porównanie modeli ze względu na sposób uogólnienia, rodzaj nadzoru, prostotę (interpretowalność), sposób użycia, zastosowanie, złożoność czasową i złożoność pamięciową.

Za model nieparametryczny (oparty o instancje) uznajemy model, który nie ma ustalonej liczby parametrów, które muszą zostać wyznaczone w procesie uczenia. W przypadku modeli parametrycznych, liczba parametrów jest stała i niezależna od ilości danych treningowych.

Model	Nadzór	Sposób uogólnienia	Prostota	Zastosowanie	Złożoność czasowa (uczenie)	Złożoność pamięciowa
<b>Regresja liniowa</b>	nad.	param.	White box	Przewidywanie wartości ciągłych	$O(nd)$	$O(d)$
<b>Regresja wielomianowa</b>	nad.	param.	White box	Modelowanie nieliniowych zależności	$O(nd)$	$O(d)$
<b>Regresja logistyczna</b>	nad.	param.	White box	Klas. binarna	$O(nd)$	$O(d)$
<b>SVM - Support Vector Machines</b>	nad.	param.	Black box	Reg., klas. binarna i wieloklasowa	$O(n^2d)$	$O(n^2)$
<b>Drzewa decyzyjne</b>	nad.	param.	White box	Klas., reg.	$O(nd \log n)$	$O(nd)$
<b>Las losowy (Random Forest)</b>	nad.	param.	Black box	Klas., reg.	$O(ndm \log n)$	$O(ndk)$
<b>Gradient Boosting</b>	nad.	param.	Black box	Klas., reg.	$O(ndm \log n)$	$O(ndk)$
<b>K-Nearest Neighbors</b>	nad.	inst.	White box	Klas., reg.	$O(nd)$	$O(nd)$
<b>DBSCAN</b>	NIEnad.	inst.	White box	Grupowanie, wykrywanie anomalii	$O(n^2)$ lub $O(n \log n)$	$O(n)$
<b>K-Means</b>	NIEnad.	param.	White box	Grupowanie, wykrywanie anomalii	$O(nkd)$	$O(nd)$

Model	Nadzór	Sposób uogólnienia	Prostota	Zastosowanie	Złożoność czasowa (uczenie)	Złożoność pamięciowa
<b>Głębokie sieci neuronowe</b>	nad.	param.	Black box	Klas., reg., rozpoznawanie wzorców, zaawansowana analiza danych	Zależy od architektury	Zależy od architektury
<b>Konw. sieci neuronowe</b>	nad.	param.	Black box	Przetwarzanie obrazów	Zależy od architektury	Zależy od architektury
<b>Rekur. sieci neuronowe</b>	nad.	param.	Black box	Przetwarzanie sekwencji, generowanie tekstu	Zależy od architektury	Zależy od architektury

Użyto oznaczeń:

- nad. - nadzorowane
- NIEnad. - nienadzorowane
- param. - parametryczny
- inst. - nieparametryczny (oparty o instancje)
- reg. - regresja
- klas. - klasyfikacja
- $n$  - liczba próbek
- $d$  - liczba cech
- $m$  - liczba modeli
- $k$  - liczba klastrów